

A contradição da IA no desenvolvimento de software

Análise comparativa de três estudos sobre produtividade de programadores

Discentes: Antonio Roger e Polyana Moraes

Os três estudos medem a mesma coisa, quanto a IA ajuda quem escreve código, e não fecham: 55,8% mais rápido, 19% mais lento, retorno crescente à expertise. A divergência vem do que cada um colocou dentro do experimento.

1. Aceleração em tarefa sintética. Peng et al. (2023) deram a 95 programadores do Upwork um servidor HTTP em JavaScript com doze testes visíveis. Com Copilot: 71 minutos, contra 161 do controle. O ganho foi maior para quem tinha menos anos de profissão. Os participantes estimaram 35% de ganho, subestimaram.

2. Desaceleração em código legado. A METR (2025) sorteou 246 tarefas reais de 16 mantenedores entre "IA permitida" e "IA proibida", em repositórios com média de 1,1 milhão de linhas e dez anos de história, onde cada dev tinha cinco anos e 1.500 commits. Resultado: 19% mais tempo. As gravações de tela mostram menos codificação e mais tempo escrevendo prompt, esperando geração e revisando saída, aceitaram menos de 44% das gerações do Cursor e gastaram 9% do tempo limpando o que aceitaram. A lentidão é maior justamente nas tarefas de alta familiaridade prévia, onde a IA não tem o conhecimento tácito do repositório.

3. Planejar versus executar. A Anthropic (2026) analisou 400 mil sessões de Claude Code. O humano toma ~70% das decisões de planejamento, o agente ~80% das de execução. Saber programar pesa pouco: as dez maiores ocupações ficam a menos de sete pontos dos engenheiros de software. O que pesa é domínio do problema, cada prompt de novato dispara 5 ações, de expert 12; sucesso verificado sobe de 15% para 33%, e sessões problemáticas terminam abandonadas em 19% dos casos de novato contra 5% a 7% dos demais.

Síntese. Tarefa curta, nova, com critério de acerto explícito: a IA substitui digitação e busca, e quem tem menos repertório ganha mais. Sistema grande, acoplado, cheio de convenção não escrita: ela cobra especificação e revisão, e o especialista gasta mais corrigindo do que gastaria escrevendo. A própria METR admite que seu resultado é compatível com aceleração em projetos greenfield.

Duas ressalvas. O estudo da Anthropic não tem grupo de controle, mostra quem extrai mais do agente, não se alguém ficou mais rápido. E sobra uma tensão real: a METR acha mais lentidão onde há mais familiaridade, a Anthropic mais sucesso onde há mais expertise. Os dois medem "experiência" de formas diferentes, e nenhum desenho arbitra o outro.